



Πίνακας περιεχομένων

Περίληψη	1
A. Εισαγωγή.....	1
A1. Το σύνολο δεδομένων.....	1
A2. Γιατί είναι σημαντικό να αναλύουμε τέτοια ιατρικά δεδομένα;2	
B. Προετοιμασία δεδομένων.....	2
B1. Καθαρισμός δεδομένων.....	2
B2. Οπτικοποίηση και Ανάλυση Ακραίων Τιμών (Outliers)	3
Γ. Μοντέλα Ταξινόμησης (Classification)	3
Γ1. Περιγραφή Αλγορίθμων Ταξινόμησης	3
Γ2. Εκπαίδευση και αξιολόγηση	4
Δ. Μοντέλα Συσταδοποίησης (Clustering).....	5
Δ1. Προετοιμασία και Ανάλυση της Μεθόδου του Αγκώνα.....	5
Δ2. Συστάδες	5
Δ3. Ιεραρχική συσταδοποίηση (Agglomerative Clustering).....	6
Δ4. Συσταδοποίηση με DBSCAN.....	6
E. Εξόρυξη Κανόνων Συσχέτισης (Association Rules).....	7
E1. Προετοιμασία Δεδομένων	7
E2. Εφαρμογή Αλγορίθμου Apriori και Αξιολόγηση Κανόνων	7

E3. Ανάλυση του Ιατρικού Προφίλ	8
E.3.1 Συμπέρασμα Κανόνων Συσχέτισης	8
ΣΤ. Συμπεράσματα και Μελλοντική Έρευνα	8
ΣΤ1. Μελλοντική Έρευνα.....	9
ΣΤ2. Διαθεσιμότητα Κώδικα και Δεδομένων	9

Περίληψη

Η τεχνική αναφορά παρουσιάζει τον σχεδιασμό και την υλοποίηση ενός συστήματος εξόρυξης γνώσης από ιατρικά δεδομένα, με στόχο τη διερεύνηση των παραγόντων που επηρεάζουν την ποιότητα του ύπνου και την καρδιαγγειακή υγεία. Αξιοποιήθηκαν αλγόριθμοι Εξόρυξης δεδομένων σε τρία στάδια: ταξινόμηση, συσταδοποίηση και κανόνων συσχέτισης. Κατά την ταξινόμηση (Classification), συγκρίθηκαν πέντε αλγόριθμοι, με τους AdaBoost και Naive Bayes να επιτυγχάνουν την υψηλότερη ακρίβεια στην πρόβλεψη διαταραχών ύπνου. Στη συνέχεια, η εφαρμογή των αλγορίθμων K-Means και DBSCAN ανέδειξε διαφορετικά ιατρικά προφίλ ασθενών, τεκμηριώνοντας τη στενή σχέση της καθιστικής ζωής και του στρες με την υπέρταση. Τέλος, η χρήση του αλγορίθμου Apriori παρήγαγε ισχυρούς κανόνες συσχέτισης,



πιστοποιώντας ότι ο συνδυασμός φυσιολογικής αρτηριακής πίεσης και καθημερινής φυσικής δραστηριότητας οδηγεί στην υψηλή ποιότητα ύπνου. Συνολικά, τα αποτελέσματα καταδεικνύουν την αποτελεσματικότητα των τεχνικών Data Mining στην εξαγωγή πολύτιμων κλινικών συμπερασμάτων για τον κλάδο της ιατρικής.

A. Εισαγωγή

Η τεχνική αναφορά περιγράφει τον σχεδιασμό ενός ολοκληρωμένου συστήματος ανάλυσης και εξόρυξης γνώσης (Data Mining) από ιατρικά δεδομένα. Ο κύριος σκοπός της είναι η εφαρμογή αλγορίθμων όπως η κατηγοριοποίηση (Classification), η συσταδοποίηση (Clustering) και η εύρεση κανόνων συσχέτισης (Association Rules) για να ανακαλυφθούν κοινά χαρακτηριστικά που συνδέουν τις καθημερινές συνήθειες ενός ατόμου με την ποιότητα ύπνου του και τη γενικότερη υγεία του.

A1. Το σύνολο δεδομένων

Το σύνολο δεδομένων (dataset) που μελετήθηκε, είναι ένα αντιπροσωπευτικό δείγμα από στοιχεία που περιγράφουν τον τρόπο ζωής ενήλικων ατόμων, και πιο συγκεκριμένα, την ποιότητα ύπνου τους. Περιλαμβάνει βασικά χαρακτηριστικά, όπως η ηλικία, το φύλο και το επάγγελμα, καθώς και κρίσιμους δείκτες υγείας. Αναλυτικότερα, περιέχει μετρήσεις για τη διάρκεια και την ποιότητα του ύπνου, τα επίπεδα στρες, την συστολική και διαστολική πίεση και τους μέσους

καρδιακούς παλμούς. Παράλληλα, καταγράφει δεδομένα φυσικής κατάστασης, όπως ο αριθμός βημάτων, το επίπεδο σωματικής δραστηριότητας και ο δείκτης μάζας σώματος (BMI). Τέλος, ένα από τα σημαντικότερα στοιχεία που υπάρχει στο σύνολο, είναι η ύπαρξη ή μη διαγνωσμένων διαταραχών ύπνου, όπως η αϋπνία (Insomnia) ή η υπνική άπνοια (Sleep Apnea).

A2. Γιατί είναι σημαντικό να αναλύουμε τέτοια ιατρικά δεδομένα;

Η υπολογιστική ανάλυση των συγκεκριμένων ιατρικών δεδομένων είναι ζωτικής σημασίας για τη σύγχρονη ιατρική έρευνα. Ο τρόπος ζωής των τελευταίων χρόνων, που συχνά χαρακτηρίζεται από αυξημένο στρες και καθιστική ζωή, επηρεάζει αρνητικά την υγεία των ενηλίκων. Μέσα από την εξερευνητική ανάλυση δεδομένων (Exploratory Data Analysis, EDA), την ομαδοποίηση των ασθενών με κοινά χαρακτηριστικά σε συστάδες και την εξαγωγή ισχυρών κανόνων συσχέτισης, καθιστούν ευκολότερο να προκύψει κάποιο ορθό συμπέρασμα. Τα συμπεράσματα τέτοιων αναλύσεων αφορούν τις διαταραχές ύπνου και μπορούν να βοηθήσουν τους επαγγελματίες υγείας, λαμβάνοντας μέτρα όπως διαγνώσεις, πρόληψη και παρεμβάσεις βελτίωσης της ποιότητας ζωής σε σύντομο χρονικό διάστημα.



B. Προετοιμασία δεδομένων

Η εξαγωγή αξιόπιστων συμπερασμάτων από οποιοδήποτε μοντέλο εξόρυξης δεδομένων, προϋποθέτει τον σωστό καθαρισμό και κατανόηση των ακατέργαστων και αδόμητων δεδομένων. Το στάδιο της Εξερευνητικής Ανάλυσης Δεδομένων (EDA) και της προεπεξεργασίας είναι καθοριστικό για την επιτυχή εφαρμογή των αλγορίθμων που ακολουθούν.


B1. Καθαρισμός δεδομένων

Το πρώτο στάδιο αφορούσε τον έλεγχο και τον καθαρισμό του συνόλου δεδομένων. Αρχικά, η μεταβλητή της αρτηριακής πίεσης 'Blood Pressure', η οποία ήταν καταχωρημένη ως δύο τιμές σε μία στήλη, διαχωρίστηκε σε δύο ποσοτικές στήλες: 'Systolic' τη συστολική και 'Diastolic' την διαστολική. Μετά την ολοκλήρωση του διαχωρισμού, η αρχική ενιαία στήλη αφαιρέθηκε από το dataset. Στη συνέχεια, παρατηρήθηκε ότι οι δύο ξεχωριστές κατηγορίες 'Normal' και 'Normal Weight' αναπαριστούν την ίδια μέτρηση του BMI, έτσι έγινε η συνένωσή τους. Πραγματοποιήθηκε έλεγχος για διπλότυπες γραμμές στο σύνολο δεδομένων, από τον οποίο επιβεβαιώθηκε ότι δεν υπήρχε καμία διπλότυπη εγγραφή. Κατά τον έλεγχο ελλειπών τιμών, διαπιστώθηκε ότι η μοναδική στήλη με κενές τιμές ήταν η 'Sleep Disorder', καταγράφοντας 219

απουσίες. Δεδομένου ότι η απουσία τιμής υποδηλώνει άτομα χωρίς διαγνωσμένη διαταραχή, τα κενά αυτά συμπληρώθηκαν με την τιμή 'None'. Τέλος, επειδή οι αλγόριθμοι κατανοούν μόνο ποσοτικές μεταβλητές, οι ποιοτικές (κατηγορικές) μεταβλητές 'Gender', 'Occupation' και 'BMI Category' μετατράπηκαν σε ποσοτικές. Αυτό επιτεύχθηκε μέσω της συνάρτησης `pd.get_dummies` (One-Hot Encoding).

B2. Οπτικοποίηση και Ανάλυση Ακραίων Τιμών (Outliers)

Για τον εντοπισμό πιθανών ακραίων τιμών, δημιουργήθηκαν θηκογράμματα (boxplots) για όλες τις αριθμητικές μεταβλητές, χρησιμοποιώντας τη χρωματική παλέτα 'twilight' διαφοροποιώντας την κάθε μεταβλητή.



Εικόνα 1: Εντοπισμός ακραίων τιμών μέσω των boxplots.

Σύμφωνα με τα παραπάνω διαγράμματα, οι μεταβλητές Age, Sleep Duration, Quality of Sleep, Physical



Activity Level, Stress Level, Daily Steps, Systolic και Diastolic παρουσίασαν μια εξαιρετικά σταθερή κατανομή. Δεν παρατηρήθηκε καμία τιμή εκτός των ορίων, υποδεικνύοντας υψηλή ποιότητα δεδομένων. Η μοναδική μεταβλητή που παρουσίασε ακραίες τιμές ήταν η 'Heart Rate'. Εκεί εντοπίστηκε μια συγκεκριμένη ομάδα ατόμων που εμφάνιζε παλμούς ηρεμίας άνω των 80 bpm. Αποφασίστηκε να μην τροποποιηθούν ή διαγραφούν, διότι η ταχυκαρδία αποτελεί πραγματική κατάσταση και όχι θόρυβο ή σφάλμα. Αν αφαιρούνταν από το σύνολο, θα αλλοιώνονταν η πληροφορία και θα προέκυπταν ανακρίβειες στα μοντέλα κατηγοριοποίησης και συσταδοποίησης.

Γ. Μοντέλα Ταξινόμησης (Classification)

Αρχικά, η μεταβλητή-στόχος 'Sleep Disorder' απομονώθηκε από τα υπόλοιπα χαρακτηριστικά, τα οποία στη συνέχεια κανονικοποιήθηκαν μέσω της κλάσης StandardScaler. Με αυτόν τον τρόπο, όλες οι μεταβλητές θα έχουν ίση βαρύτητα κατά την εκπαίδευση. Το σύνολο δεδομένων διαχωρίστηκε σε δεδομένα εκπαίδευσης (train 80%) και δοκιμής (test 20%). Για τον διαχωρισμό χρησιμοποιήθηκε δειγματοληψία stratify=y, διασφαλίζοντας ότι η αναλογία των κλάσεων της μεταβλητής-στόχου παρέμεινε σταθερή και στα δύο υποσύνολα. Επειδή τα ιατρικά datasets συχνά παρουσιάζουν ανισορροπία στις

κλάσεις, εφαρμόστηκε η τεχνική SMOTE (Synthetic Minority Over-sampling Technique). Δημιούργησε τεχνητά δείγματα για τις κλάσεις με λίγους ασθενείς στο σύνολο εκπαίδευσης, αποτρέποντας τη μεροληψία των μοντέλων υπέρ της πλειοψηφικής κλάσης.

Γ1. Περιγραφή Αλγορίθμων Ταξινόμησης

Ο αλγόριθμος Decision tree δομεί ένα μοντέλο πρόβλεψης ιεραρχικά, με τη μορφή δέντρου. Τα δεδομένα διαχωρίζονται επαναληπτικά σε μικρότερα υποσύνολα με βάση συγκεκριμένους κανόνες, μέχρι να καταλήξουν στα φύλλα, δηλαδή την τελική διάγνωση της πάθησης. Είναι ιδιαίτερα δημοφιλής στον ιατρικό τομέα λόγω της υψηλής και άμεσης ερμηνευσιμότητας των αποφάσεών του.

Ο k-Nearest Neighbors βασίζεται στον υπολογισμό της ευκλείδειας απόστασης μεταξύ των δεδομένων. Για να ταξινομήσει έναν νέο ασθενή, εξετάζει τους k πιο παρόμοιους ασθενείς στο σύνολο εκπαίδευσης. Στην παρούσα εργασία, ορίστηκε η_neighbors=5, που σημαίνει ότι η τελική διάγνωση προκύπτει από τα 5 κοντινότερα ιατρικά προφίλ.

Ο Naive Bayes είναι ένα πιθανοτικό μοντέλο που βασίζεται στο θεώρημα του Bayes. Υπολογίζει την πιθανότητα να ανήκει ένας ασθενής σε μια



συγκεκριμένη κατηγορία διαταραχής. Θεωρείται αφέλης (naive) διότι κάνει την αυστηρή μαθηματική παραδοχή ότι όλα τα χαρακτηριστικά είναι απολύτως ανεξάρτητα μεταξύ τους. Αν και αυτή η συνθήκη σπάνια ισχύει, ο αλγόριθμος συχνά επιτυγχάνει εξαιρετική και ταχύτατη προβλεπτική ικανότητα.

Ο Random Forest εφαρμόζει μια προηγμένη μέθοδο συνόλου, βασισμένη στην τεχνική Bagging. Πιο αναλυτικά, αντί να εξάγει συμπεράσματα από ένα μόνο δέντρο απόφασης, κατασκευάζει ένα πλήθος από ανεξάρτητα δέντρα κατά τη διάρκεια της εκπαίδευσης. Η τελική ταξινόμηση εξάγεται από τον συνδυασμό όλων των επιμέρους δέντρων, που μειώνει τη διακύμανση του μοντέλου και αποτρέπει τον κίνδυνο υπερεκπαίδευσης (overfitting).


Ο adaBoost είναι μία διαφορετική προσέγγιση συνόλου. Σε αντίθεση με το Random Forest όπου τα δέντρα είναι ανεξάρτητα, ο AdaBoost λειτουργεί σειριακά. Δημιουργεί πολλαπλά μοντέλα, όπου κάθε νέο μοντέλο εκπαιδεύεται με σκοπό να διορθώσει αποκλειστικά τα λάθη του προηγούμενου μοντέλου. Δηλαδή τους ασθενείς που ταξινομήθηκαν εσφαλμένα. Αυτή η προσαρμοστική διαδικασία βελτίωσης αυξάνει δραματικά την ακρίβειά του.

Γ2. Εκπαίδευση και αξιολόγηση

Στο ισορροπημένο πλέον σύνολο εκπαίδευσης, δοκιμάστηκαν πέντε

αλγόριθμοι ταξινόμησης: Decision Tree, k-Nearest Neighbors (kNN, με 5 γείτονες), Naive Bayes, Random Forest και AdaBoost. Συγκεκριμένα, οι αλγόριθμοι Naive Bayes και AdaBoost παρουσίασαν την υψηλότερη ακρίβεια Accuracy 92% . Ακολούθησαν ο αλγόριθμος k-Nearest Neighbors με ακρίβεια 90.67% και το Decision Tree με 89.33%. Οι αναλυτικές αναφορές ταξινόμησης (classification reports) ανέδειξαν ισχυρές μετρικές ακρίβειας (precision, recall), δείχνοντας την ισχυρή αξιοπιστία των προβλέψεων.

Δ. Μοντέλα Συσταδοποίησης (Clustering)



Εικόνα 2: Μέθοδος του αγκώνα (Elbow method) για K-Means.

Δ1. Προετοιμασία και Ανάλυση της Μεθόδου του Αγκώνα

Για τον ακριβή προσδιορισμό του βέλτιστου αριθμού συστάδων στον K-Means, αξιοποιήθηκε η Μέθοδος του Αγκώνα (Elbow Method). Στο παραπάνω διάγραμμα, ο οριζόντιος άξονας



αναπαριστά τον αριθμό των υπό δοκιμή συστάδων, ενώ ο κατακόρυφος το Άθροισμα των Τετραγώνων των Σφαλμάτων (WCSS), το οποίο μετρά τη διασπορά των δεδομένων στο εσωτερικό κάθε ομάδας.

Παρατηρείται ότι καθώς ο αριθμός των συστάδων αυξάνεται από 1 έως 4, η τιμή του WCSS μειώνεται απότομα, δείχνοντας τη μεταβλητότητα των δεδομένων. Ωστόσο, στο σημείο $k=4$ παρατηρείται ο 'αγκώνας' της καμπύλης. Για τιμές μεγαλύτερες του 4, η κλίση της γραμμής ομαλοποιείται, δηλώνοντας ότι η δημιουργία επιπλέον συστάδων δεν προσφέρει ακραία μείωση του σφάλματος. Άρα επιλέγοντας την τιμή $k=4$, γίνεται ο ακριβέστερος διαχωρισμός των ασθενών.

Δ2. Συστάδες

Η εφαρμογή του αλγορίθμου K-Means οδήγησε στον διαχωρισμό του δείγματος σε τέσσερις ιατρικές ομάδες:


1. Συστάδα 0, ισορροπημένη ομάδα μέσης ηλικίας: Άτομα με μέση ηλικία τα 40 έτη που έχουν υγιή ρουτίνα. Καταγράφουν τη μεγαλύτερη διάρκεια ύπνου (7.7 ώρες) και υψηλή ποιότητα ύπνου (8.0), μέτρια φυσική δραστηριότητα, χαμηλούς παλμούς (68.2 bpm) και φυσιολογική αρτηριακή πίεση (123.4/80.6).
2. Συστάδα 1, μεγαλύτερη ηλικία με καλό ύπνο αλλά υπέρταση: Οι γηραιότεροι συμμετέχοντες με μέση ηλικία 51.8. Αν και έχουν το λιγότερο στρες (3.5) και την υψηλότερη ποιότητα ύπνου (8.1), ακολουθούν καθιστική ζωή (6393 βήματα ημερησίως). Έτσι εξηγείται και η αυξημένη αρτηριακή πίεση (137.8/92.7).
3. Συστάδα 2, νεαρή ομάδα με καθιστική ζωή και στρες: Η νεότερη ομάδα του δείγματος, 37.8 έτη, με την πιο έντονη καθιστική ζωή, τα χαμηλότερα επίπεδα φυσικής δραστηριότητας (40.4) και βημάτων (5516.7). Η έλλειψη άσκησης συνοδεύεται από υψηλά επίπεδα στρες (7.2), τα οποία αντανakλώνται στη χαμηλή ποιότητα (6.0) και διάρκεια ύπνου (6.4 ώρες).
4. Συστάδα 3 υπερδραστήρια αλλά υψηλά στρεσαρισμένη ομάδα: Μεσήλικες 49.8 ετών με πολύ υψηλή φυσική δραστηριότητα (δείκτης 90.0 και 10000 βήματα). Παρά την άσκηση, καταγράφουν το απόλυτο μέγιστο επίπεδο στρες 8.0, που σχετίζεται με την πιο χαμηλή διάρκεια ύπνου (6.1 ώρες), τους υψηλότερους παλμούς (75.0 bpm) και σοβαρή υπέρταση (140.0/95.0).



Δ3. Ιεραρχική συσταδοποίηση (Agglomerative Clustering)

Εφαρμόστηκε ο αλγόριθμος Ιεραρχικής Συσταδοποίησης με χρήση του κριτηρίου ελαχιστοποίησης της διακύμανσης του Ward.

Στο δενδρόγραμμα, ο κατακόρυφος άξονας (Απόσταση Ward) δείχνει τον βαθμό ανομοιότητας μεταξύ των ομάδων που ενώνονται. Παρατηρούμε ότι οι ενώσεις σε χαμηλά επίπεδα απόστασης είναι πολλές. Αναζητώντας τη μεγαλύτερη κατακόρυφη απόσταση χωρίς διακλαδώσεις, τοποθετήσαμε μια οριζόντια διακεκομμένη γραμμή στο ύψος $y=25$. Σε αυτό το ύψος, η νοητή γραμμή τέμνει ακριβώς 4 κάθετους κλάδους. Έτσι, επιβεβαιώνεται ότι το βέλτιστο πλήθος συστάδων για τα συγκεκριμένα δεδομένα καθορίζεται οριστικά σε $k=4$.




Εικόνα 3: Δενδροδιάγραμμα ιεραρχικής συσταδοποίησης.

Δ4. Συσταδοποίηση με DBSCAN

Ο DBSCAN είναι βασισμένος στην πυκνότητα (density-based) και έχει το πλεονέκτημα ότι δεν απαιτεί εκ των

προτέρων καθορισμό του αριθμού των συστάδων, ενώ παράλληλα εντοπίζει τις ακραίες τιμές. Επιλέχθηκε ως ελάχιστο μέγεθος γειτονιάς $\text{min_samples} = 5$ για ένα σχετικά μικρό dataset, ώστε να αποφευχθεί η δημιουργία υπερβολικά πολλών μικρο-συστάδων.



Εικόνα 4: Διάγραμμα K-distance.

Από την εικόνα 4 προκύπτει $\text{eps} = 1.5$ ως το σημείο μέγιστης καμπυλότητας ακριβώς πριν η απόσταση από τον 5ο κοντινότερο γείτονα αυξηθεί εκθετικά.

Από την εφαρμογή του αλγορίθμου, διαπιστώνουμε ότι ο αλγόριθμος ταξινομήσε 19 εγγραφές στην κλάση -1. Αυτό επιβεβαιώνει την αρχική μας ανάλυση κατά την προεπεξεργασία (μέσω των boxplots), όπου είχαμε εντοπίσει άτομα με πολύ υψηλούς καρδιακούς παλμούς. Επίσης δημιουργήθηκαν 10 συστάδες. Η ομάδα 0 περιλαμβάνει 138 άτομα. Επειδή αποτελεί τη μεγαλύτερη ομάδα, είναι και ο πιο συνηθισμένος τρόπος ζωής. Οι υπόλοιπες συστάδες από 25 έως 33 άτομα η καθεμία αντιπροσωπεύουν ανθρώπους με παρόμοιες συνήθειες. Οι



ομάδες 1 και 3 με 6 άτομα οριακά
ξεπέρασαν τον αριθμό `min_samples`.

Ε. Εξόρυξη Κανόνων Συσχέτισης (Association Rules)

Ε1. Προετοιμασία Δεδομένων

Για την εφαρμογή του αλγορίθμου εξαγωγής κανόνων συσχέτισης `Apriori`, ακολούθησε προεπεξεργασία των δεδομένων, καθώς ο αλγόριθμος λειτουργεί αποκλειστικά με κατηγορικά δεδομένα. Αρχικά, όλες οι συνεχείς αριθμητικές μεταβλητές (Ηλικία, Διάρκεια και Ποιότητα Ύπνου, Φυσική Δραστηριότητα, Στρες, Καρδιακοί Παλμοί, Βήματα και Αρτηριακή Πίεση) μετασχηματίστηκαν σε τρεις κατηγορίες `Low`, `Medium`, `High` με την συνάρτηση `pd.qcut`. Έπειτα, εφαρμόστηκε η τεχνική `One-Hot Encoding` με τη συνάρτηση `pd.get_dummies`, όπως έγινε και στην προεπεξεργασία μετατρέποντας όλα τα χαρακτηριστικά σε μορφή `Boolean`. Τέλος, η στήλη `'Person ID'` αφαιρέθηκε από το `dataset`, γιατί η διατήρηση ενός μοναδικού αναγνωριστικού για κάθε ασθενή θα μπέρδευε τον αλγόριθμο κατά την αναζήτηση μοτίβων.

Ε2. Εφαρμογή Αλγορίθμου Apriori και Αξιολόγηση Κανόνων

Ο αλγόριθμος `Apriori` εκτελέστηκε θέτοντας ως `min_support=0.15`, ώστε να απομονωθούν μόνο τα μοτίβα που

εμφανίζονται σε ένα μεγάλο τμήμα του δείγματος.

Από την εκτέλεση του αλγορίθμου, και ταξινομώντας τους κανόνες με βάση τη μετρική `Lift`, προέκυψε ότι οι 10 ισχυρότεροι κανόνες περιγράφουν το ίδιο ακριβώς ιατρικό προφίλ. Οι κανόνες αυτοί αφορούν το 15.5% `Support` του συνολικού δείγματος, ενώ παρουσιάζουν απόλυτη εμπιστοσύνη `Confidence 100%` και εξαιρετικά υψηλό `Lift 6.448`.

Ε3. Ανάλυση του Ιατρικού Προφίλ

Η έρευνα των ισχυρότερων κανόνων όπως οι κανόνες 2271-2274 και 3461, αποδεικνύει μια ξεκάθαρη συσχέτιση: Η μεσαία και φυσιολογική αρτηριακή πίεση συνδέεται με την μέτρια φυσική δραστηριότητα `Daily Steps Medium` και μεσαία ποιότητα ύπνου. Επιπλέον, ο κανόνας 3461 συμπεριλαμβάνει το φύλο, συμπεραίνοντας ότι αυτό το συγκεκριμένο μοτίβο τρόπου ζωής συναντάται συνήθως στους άνδρες του δείγματος.

Ε.3.1 Συμπέρασμα Κανόνων Συσχέτισης

Το εξαιρετικά υψηλό `Lift 6.44`, επιβεβαιώνει ότι η φυσική άσκηση συνδέεται άμεσα με τη φυσιολογική αρτηριακή πίεση και την καλή ποιότητα ύπνου. Το γεγονός ότι η μετρική `Confidence` αγγίζει το απόλυτο 100%, εκφράζει ότι σε ολόκληρο το `dataset`



που εξετάζεται, όποιος ασθενής είχε αυτόν τον συνδυασμό πίεσης και βημάτων, δεν είχε ποτέ κακή ποιότητα ύπνου.

ΣΤ. Συμπεράσματα και Μελλοντική Έρευνα

Η παρούσα μελέτη αποδεικνύει την δυναμική των αλγορίθμων Εξόρυξης Γνώσης στον τομέα υγείας, ειδικότερα στην κατανόηση των παραγόντων που επηρεάζουν την ποιότητα ύπνου και τις διαταραχές που προκύπτουν. Η σημαντικότερη έκβαση της έρευνας είναι η ομοιότητα των αποτελεσμάτων όλων προσεγγίσεων.

Μέσω της ταξινόμησης, τα μοντέλα όπως ο AdaBoost και ο Naive Bayes απέδειξαν ότι μεταβλητές όπως η αρτηριακή πίεση, οι καρδιακοί παλμοί και τα επίπεδα στρες έχουν ισχυρή προβλεπτική ικανότητα, καταφέροντας να διαγνώσουν διαταραχές όπως η αϋπνία και η υπνική άπνοια με ακρίβεια 92%.

Μέσω της συσταδοποίησης, ο K-Means και ο DBSCAN, οι οποίοι δε γνώριζαν τις διαγνώσεις, ομαδοποίησαν τους ασθενείς σε διαφορετικά προφίλ. Κατέληξαν στο αποτέλεσμα ότι η ομάδα με την περισσότερη καθιστική ζωή, τα υψηλότερα επίπεδα στρες και με ταχυπαλμίες ταυτίζεται με τη χαμηλότερη διάρκεια και ποιότητα ύπνου.

Μέσω των κανόνων συσχέτισης Apriori οι κανόνες επιβεβαίωσαν την εγκυρότητα των προηγούμενων αποτελεσμάτων με Confidence 100%. Έτσι, η διατήρηση της καθημερινής δραστηριότητας, με φυσιολογική πίεση, οδηγεί σε καλό ύπνο.

Με αυτόν τον τρόπο, η ένωση των τριών μεθόδων επικυρώνει ότι η καθιστική ζωή, οι υψηλοί παλμοί ηρεμίας και η υπέρταση όταν αθροίζονται επιβαρύνουν το νευρικό σύστημα, υποβαθμίζοντας την ποιότητα ύπνου.

ΣΤ1. Μελλοντική Έρευνα

Παρά τα εξαιρετικά αποτελέσματα των μοντέλων που αναπτύχθηκαν, η παρούσα εργασία θέτει τις βάσεις για περαιτέρω έρευνα και βελτιστοποίηση. Αρχικά θα μπορούσαν να προστεθούν νευρωνικά δίκτυα με την συλλογή μεγαλύτερου όγκου δεδομένων (Big Data). Δηλαδή να εκπαιδευτούν αρχιτεκτονικές Βαθιάς Μάθησης όπως τα πολυστρωματικά Perceptrons (MLP). Με αποτέλεσμα να εντοπίσουν πιο πολύπλοκες, συσχετίσεις μεταξύ των φυσιολογικών δεικτών. Τέλος η ενσωμάτωση δεδομένων χρονοσειρών (Time-Series Data) θα μπορούσε να προσφέρει εξατομικευμένη βοήθεια για το κάθε άτομο επιτυγχάνοντας περισσότερη ακρίβεια. Για παράδειγμα, θα προστίθονταν έξυπνες συσκευές όπως smartwatches, συσκευές IoT και διάφοροι αισθητήρες που να συλλέγουν δεδομένα πραγματικού χρόνου για την



κατάσταση των ασθενών. Τέλος, είναι εξίσου σημαντική η παρακολούθηση του ίδιου δείγματος ασθενών σε βάθος χρόνου , ώστε να μελετηθεί πώς η αλλαγή των συνηθειών επηρεάζει τη μετάβαση ενός ασθενούς από μια νοσηρή συστάδα σε μια υγιή.

ΣΤ2. Διαθεσιμότητα Κώδικα και Δεδομένων

Η πλήρης υλοποίηση της παρούσας εργασίας πραγματοποιήθηκε σε περιβάλλον Python Jupyter Notebook. Για την εκτέλεση των αλγορίθμων, τη δημιουργία των διαγραμμάτων και την προεπεξεργασία, χρησιμοποιήθηκαν οι βιβλιοθήκες *pandas*, *scikit-learn*, *matplotlib* και *seaborn*. Ο πηγαίος κώδικας, είναι διαθέσιμος στο GitHub στη διεύθυνση:

github.com/konstantinaklei/datamining-project